

Explaining Multimodal Emotion Recognition: How Do AI Models Balance Content and Tone?

이지호 이상엽



연구 목표

AI 감정 인식 과정에서 “언어 정보(Semantics)”와 “음향 정보(Prosody)”가 서로 어떤 기여를 하는지 정량·정성적으로 규명하는 것

핵심 방향

- **Dual-Signal Contribution** 분석
텍스트 의미 vs 음향·억양 신호가 감정 판단에 미치는 영향 비교
- **Feature Importance** 파악
Prosody(속도·톤·강세) 및 언어적 표현이 정서 분류에 기여하는 정도 분석

Target OutCome

- 감정 인식 시 어떤 신호가 어떤 상황에서 더 유효한지 설명 가능한 인사이트 도출
- 감정 AI 설계 시 모달 우선순위·설계 방향성 제안
- XAI 관점에서 판단 근거를 구조화해 해석 가능성 확보

AI는 무엇을 기준으로 판단하는가?

언어 정보(Semantics)와 음향 정보(Prosody)가 어떤 기여를 하는지 정량·정성적으로 규명하는 것

"참 잘했다."

핵심 방향

텍스트 분석: 100% 긍정 (칭찬)

- Dual-Signal Contribution 분석
텍스트 의미 vs 음향·억양 신호가 감정 판단에 미치는 영향 비교
- Feature Importance 파악
Prosody(속도·톤·강세) 및 언어적 표현이 정서 분류에 기여하는 정도 분석

억양 분석: 100% 부정 (비꼬는 어조)

- 감정 인식 시 어떤 신호가 어떤 상황에서 더 유효한지 설명 가능한 인사이트 도출

이러한 '**불일치(Mismatch)**' 를 AI가 어떻게 판단하고 해결할 것인가가 본 연구의 핵심 과제입니다.

- XAI 관점에서 판단 근거를 구조화해 해석 가능성 확보

감정 인식의 핵심 입력구조에 대한
실증적 이해 필요

- 현재 감정 AI는 텍스트·음성을 조합하지만 각 신호의 영향력과 기여도가 명확히 설명되지 않음
- 이를 해석하면 AI의 추론 경로를 더 신뢰성 있게 제시 가능

Prosody의 정서 전달력 주목

- 사람 간 의사소통에서 정서 정보의 70% 이상이 비언어 신호(tone·pitch·rate)
- Prosody가 중요하지만 모델 관점에서 그 기여도는 덜 연구됨

Explainable AI(XAI) 적용 시
가치가 큼

- 감정 AI는 의료·온라인 상담·고객 VOC 분석 등 신뢰 기반 도메인에서 활용도 높음
→ 해석력 필수

경량 모델·RAG·디바이스 온보드 등
확장성

- 텍스트/음향 기여도를 알면
→ 입력 축소·모델 경량화·도메인 최적화 설계 가능
→ 서비스 적용 시 운영 효율 증가

멀티모달 감정 인식 모델 구축

- 텍스트(BERT) + 음성(wav2vec2 or Mel-spectrogram CNN)

XAI 기법 적용

- SHAP → 각 모달별 특징 중요도 계산
- Grad-CAM → 음성 스펙트로그램 시각화

근거 비중 비교

- 감정별로 Text/Audio 기여도 비율 산출 (예: 분노: 70% 억양 / 슬픔: 55% 텍스트)

Data set: MELD (Multimodal EmotionLines Dataset)

-대화 기반 감정 데이터셋 (텍스트 + 오디오 + 감정 라벨)

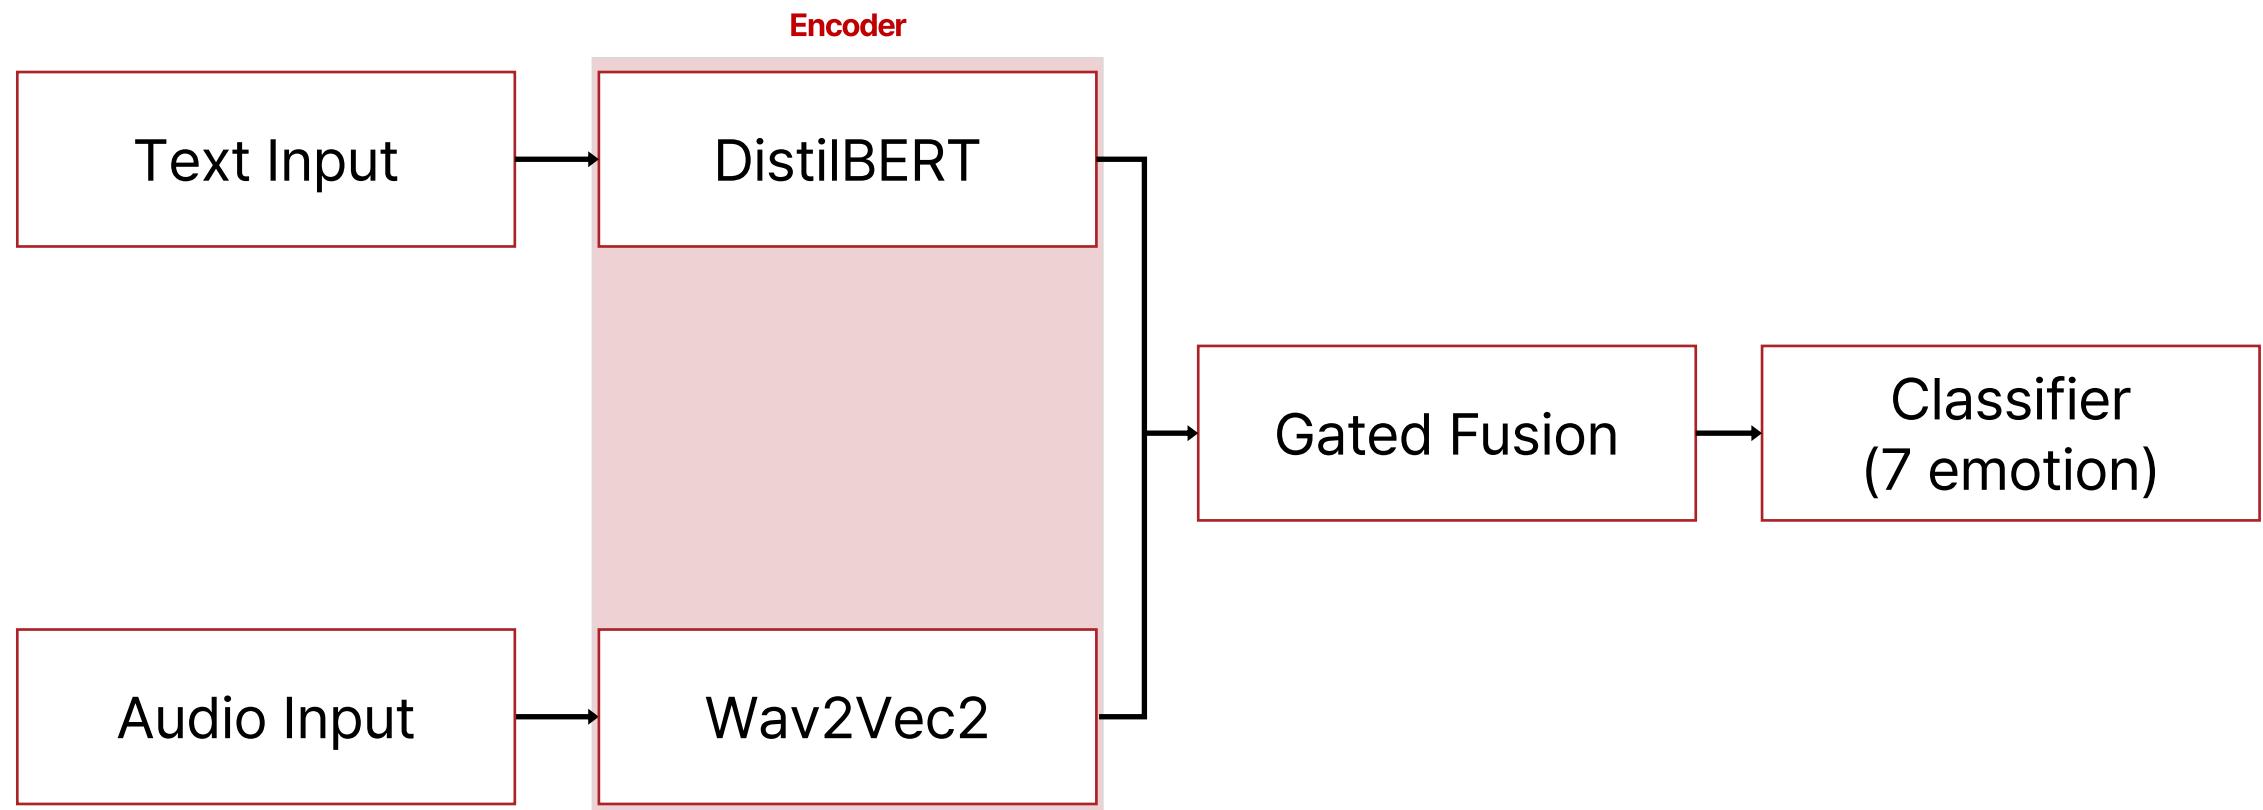
-Emotion class: 7(Anger, Disgust, Fear, Joy, Neutral, Sadness, Surprise)

Text Encoder: DistilBERT-base-uncased(hugging face)

-대사 내용을 입력을 받아 **단어 의미 기반 감정 단서** 추출

Audio Encoder:Wav2Vec2-base (Hugging Face)

-억양, 속도, 강세 등 **감정적 음성 특징** 추출



텍스트 또는 오디오를 각각 제거(masking)했을 때 감정 예측 확률이 얼마나 변하는가?
어떤 feature가 더 중요하게 감정을 추출할 때 중요하게 적용되는가?

| 실험 | 입력 구성 | 의미 |
|----------------------|----------------------|-----------|
| Text Masking | [MASK] or 빈 문장 | 말의 내용 제거 |
| Audio Masking | 무음 or 노이즈 대체 | 억양 제거 |
| 비교 | 예측 확률 변화(Δ) | 각 모달의 중요도 |

예시 기대 결과

텍스트 SHAP: “정말”, “미쳤다” → 분노에 높은 기여

음성 Grad-CAM: 고주파(2–4 kHz), 급격한 pitch 상승 → 분노 신호
기여도 비교:

분노: Audio 72% / Text 28%

슬픔: Audio 55% / Text 45%

행복: Text 60% / Audio 40%

결론

AI는 감정 종류에 따라 “내용 vs 억양” 의존도가 다르다.
이는 인간의 감정 인식 패턴과 유사한지 비교 가능.

| 분야 | 기대효과 |
|-------------------|-------------------------------------|
| AI Explainability | 블랙박스 감정 인식 모델의 내부 판단 근거를 해석 |
| Human Alignment | 인간 감정 판단 구조와 AI의 근거 비교 |
| 모델 개선 | 특정 감정에 대한 모달 편향(예: 음성 과의존) 보정 가능 |
| 응용 가능성 | 감정 챗봇, 상담 분석, 감정 TTS, 인간-로봇 상호작용 개선 |